

UNIVERSIDADE DO VALE DO ITAJAÍ – UNIVALI
ESCOLA POLITÉCNICA

THIAGO YUKIO HORITA PACHECO

RELATÓRIO PROJETO M1

OPERAÇÕES PONTUAIS E FILTRAGEM ESPACIAL

Pipeline de Melhoria de Imagens Médicas Aplicado a Imagens de Melanoma (Base ISIC)

ITAJAÍ
2026

1. Identificação do autor e do trabalho

Aluno: Thiago Yukio Horita Pacheco

Instituição: Universidade do Vale do Itajaí — UNIVALI

Curso: Engenharia da Computação

Disciplina: Processamento de Imagens

Projeto: M1 — Operações Pontuais e Filtragem Espacial, aplicadas a um pipeline de melhoria de imagens médicas de melanoma (base ISIC)

Professor: Felipe Viel

2. Enunciado do Projeto

O projeto foi proposto pela disciplina de Processamento de Imagens com o objetivo de consolidar o aprendizado sobre reconhecimento de imagem e processamento digital de imagens, a partir do desenvolvimento de um pipeline de melhoria de imagens médicas utilizando exclusivamente operações pontuais e técnicas de filtragem espacial implementadas pelos próprios alunos, sem uso de funções prontas de filtragem ou de transformação de intensidade oferecidas por bibliotecas prontas (como as funções de suavização, equalização ou aguçamento do OpenCV).

O conjunto de dados utilizado é o International Skin Imaging Collaboration (ISIC), composto por imagens de lesões de pele, com foco na categoria de melanoma. O enunciado solicitava a seleção de três a quatro imagens representativas de uma mesma região anatômica, priorizando imagens com diferenças perceptíveis de contraste, ruído ou definição estrutural, e a construção de um pipeline próprio contendo, no mínimo: (i) inserção controlada de ruído artificial; (ii) uma técnica de transformação de intensidade (operação pontual); (iii) uma técnica de suavização (filtragem espacial); (iv) uma técnica de aguçamento (filtragem espacial); (v) pelo menos duas configurações diferentes do pipeline, comparadas visual e quantitativamente por meio de métricas de qualidade.

O objetivo do trabalho não era simplesmente aplicar filtros, mas investigar como diferentes transformações alteram as características visuais da imagem, determinando por meio de métricas quantitativas qual combinação apresenta o melhor compromisso entre melhoria de contraste, redução de ruído e preservação de detalhes relevantes.

3. Explicação e contexto da aplicação para compreensão do problema tratado pela solução

Imagens de dermatoscopia, como as do conjunto ISIC, frequentemente apresentam variações de iluminação, contraste, ruído de captura e presença de artefatos (pelos, vinhetas de borda, reflexos) que podem prejudicar tanto a interpretação visual por especialistas quanto o desempenho de etapas posteriores de classificação automática de lesões. O objetivo deste trabalho é construir um pipeline de pré-processamento capaz de reduzir ruído e realçar estruturas relevantes da lesão, sem introduzir artefatos que comprometam essa interpretação.

Foram então selecionadas quatro imagens de melanoma da base ISIC (ISIC_0000398, ISIC_0010208, ISIC_0010313, ISIC_0010737), escolhidas por apresentarem cada uma características visuais distintas entre si. Assim permitindo avaliar a robustez do pipeline diante de diferentes condições de entrada. A escolha de quatro imagens atende ao intervalo de três a quatro imagens estabelecido no enunciado e permite comparar o comportamento do pipeline em imagens com características visuais distintas.

4. Desenvolvimento da primeira configuração

O pipeline foi estruturado na seguinte ordem: seleção das imagens -> conversão das imagens para escala de cinza ponderada -> inserção de ruído controlado -> suavização (filtragem espacial) -> operação pontual -> aguçamento (filtragem espacial) -> avaliação por métricas de qualidade. Essa ordem se difere da sequência sugerida, onde no enunciado do trabalho a operação pontual vem antes da suavização. Essa escolha foi feita a fim de evitar com que a correção de contraste amplifique também os pixels de ruído ainda presentes na imagem, que se mostraram relevantes nos testes realizados.

4.1 Seleção e caracterização da imagens

As quatro imagens usadas no experimento aparecem na Figura 1. Visualmente, elas apresentam diferenças de distribuição de intensidades, contraste local e presença de estruturas de fundo. A primeira imagem foi escolhida devido a ter uma lesão meio definida, escura mas dispersa, com variações internas, assim tendo um contorno irregular; a segunda imagem possui uma região de baixo contraste em relação a pele, sendo assim pouco definida; a terceira imagem apresenta uma lesão definida e bem delimitada, com uma intensidade diferente e com contraste alto em relação ao fundo; e a quarta possui uma luminosidade mais clara e possui pelos evidentes próximos a lesão.



Figura 1 — Quatro imagens originais utilizadas no experimento.

4.2 Conversão para escala de cinza ponderada

A conversão para grayscale ponderado foi utilizada como etapa de normalização para permitir que as operações espaciais e a avaliação quantitativa fossem feitas em uma única banda de intensidade. Os pesos utilizados foram 0,299 para B, 0,587 para G e 0,114 para R, conforme implementado no notebook.




Figura 2 — Imagens após a conversão para grayscale ponderado.

4.3 Inserção de ruído controlado

Foi adicionado ruído gaussiano, por meio da função random noise da biblioteca skimage, às imagens em escala cinza ponderada. Foram testados três níveis de variância: 0,001, 0,01 e 0,05. A escolha da variância foi a de 0,01 para que a imagem não fique com um ruído muito fraco e nem com uma degradação excessiva. A figura 3 mostra o nível selecionado para as etapas seguintes.




Figura 3 — Imagens em grayscale ponderado com ruído gaussiano de variância 0,01.

4.4 Suavização (Filtragem Espacial)

A suavização foi implementada por meio de um filtro de média, aplicado via convolução própria (função `conv2d` que cria uma borda por reflexão usando `np.pad` e percorre os pixels da imagem, calculando a soma do produto entre a janela local e o kernel).

Foram testados kernels de tamanho 3×3 , 5×5 , 7×7 , 9×9 e 11×11 , comparando cada resultado à imagem original (antes do ruído) por meio de PSNR e SSIM. O tamanho 7×7 foi escolhido como ponto de equilíbrio: é o maior kernel em que todas as quatro imagens ainda apresentam ganho de SSIM; o SSIM da Imagem 4 atinge o pico em 7×7 e decai a partir de 9×9 , enquanto seu PSNR já decai a partir de 7×7 e, a partir de 9×9 - 11×11 , também de SSIM, indicando perda de estrutura real da lesão, não apenas remoção de ruído.



Figura 4 — Resultado da suavização com kernel de média 7×7 , configuração adotada no pipeline.

4.5 Operação Pontual

A operação pontual escolhida foi a correção gama. A escolha partiu do diagnóstico dos histogramas das imagens após a suavização 7×7 (Figura 5): nas quatro imagens, o pico se concentra em intensidades médias a altas (pele clara), com uma cauda longa em direção aos tons escuros (lesão), caracterizando histogramas assimétricos e não gaussianos. Segundo o material da disciplina, o alargamento de contraste linear é adequado a histogramas de forma gaussiano ou quase-gaussiana, o que não ocorre aqui, enquanto a transformação de potência (gama) é descrita como capaz de mapear uma faixa estreita de valores de entrada em uma faixa mais ampla de saída, o que corresponde ao padrão observado.




Figura 5 — Primeira configuração: resultado dos histogramas das imagens com suavização kernel de média 7x7.

O parâmetro gama de cada imagem foi calculado automaticamente a partir da média de intensidade da imagem, buscando levá-la a uma média-alvo normalizada de 0.5 (função `auto_gamma`). Essa escolha permite que cada imagem receba um ajuste diferente, em vez de aplicar um único valor de gamma para todo o conjunto. Entretanto, a primeira configuração mostrou que esse mecanismo pode gerar um ajuste excessivo em imagens com distribuição de intensidades muito diferente das demais.



Figura 6 — Primeira configuração: resultado da correção gama automática após a suavização 7x7.

4.6 Aguçamento (Filtragem Espacial)

A etapa de aguçamento foi implementada por meio da técnica de Unsharp Masking / High-Boost Filtering, na qual o "detalhe" da imagem é extraído como a diferença entre a imagem processada e uma versão borrada dela mesma, sendo então somado de volta com peso k . Essa técnica foi preferida ao Laplaciano puro por possuir controle nativo de intensidade do realce (o parâmetro k).

O kernel de borramento interno do Unsharp Masking foi definido como 3x3, e o peso como $k = 1,0$ (unsharp masking clássico, sem amplificação adicional). O tamanho do kernel foi escolhido testando 3x3, 5x5 e 7x7 (Tabela 5): o 3x3 obteve o maior PSNR e SSIM nas quatro imagens, com queda consistente conforme o kernel aumentava. O valor de k não foi variado, o que fica registrado como limitação.




Figura 7 — Primeira configuração: imagens após o realce High-Boost de kernel 3x3.

4.7 Aplicação de métricas

Dentre as métricas apresentadas em aula (MSE, RMSE, PSNR, SSIM e GMSD), foram selecionadas PSNR e SSIM. O PSNR foi escolhido por ser indicado no material da disciplina como especialmente adequado para avaliar filtros de suavização; o SSIM foi escolhido por avaliar semelhança estrutural (não apenas diferença numérica de intensidade), sendo mais relevante para verificar se a estrutura da lesão foi preservada ao longo do pipeline — o que importa clinicamente mais do que a fidelidade exata de cada pixel.

Imagem	Etapa	PSNR (db)	SSIM
1	Com Ruído	20.03	0.0983
2	Com Ruído	20.05	0.1155
3	Com Ruído	20.00	0.0908
4	Com Ruído	20.68	0.1996
1	Filtrada (Suavização 7x7)	35.99	0.8733
2	Filtrada (Suavização 7x7)	34.05	0.8467
3	Filtrada (Suavização 7x7)	36.08	0.8724
4	Filtrada (Suavização 7x7)	29.55	0.7960
1	Processada (Gamma)	26.32	0.8604
2	Processada (Gamma)	17.24	0.7766
3	Processada (Gamma)	21.72	0.8442
4	Processada (Gamma)	10.07	0.5762
1	Final (Highboost kernel 3x3)	26.41	0.7868

2	Final (Highboost kernel 3x3)	17.32	0.6998
3	Final (Highboost kernel 3x3)	21.83	0.7626
4	Final (Highboost kernel 3x3)	10.09	0.4879

Tabela 1 — Métricas aplicadas à primeira configuração.

5 Desenvolvimento da segunda configuração

5.1 Reavaliação de possíveis melhorias

Por meio dos resultados obtidos da Tabela 1, foi identificado que a imagem 4 se diferenciava bastante das demais, e que após a correção gamma os valores de sua métrica caíram drasticamente, e na imagem é possível notar um forte escurecimento. Por isso então, seguindo o que foi solicitado no enunciado, foi criada duas configurações diferindo apenas um parâmetro, que neste caso foi a regra no cálculo do gama, onde foi limitado o valor de gamma para que o valor das métricas não saísse de controle.

- Configuração 1: gama calculado automaticamente sem limite (auto_gamma).
- Configuração 2: gama calculado automaticamente e limitado ao intervalo [0.5, 2.0] (auto_gamma_limitado).

Imagem com correção gamma (limitado)




Figura 8 — Segunda configuração: resultado da correção gama (limitado) automática após a suavização 7×7.

Após a correção gamma, foi feito assim como na primeira configuração o realce do High-Boost.




Figura 9 — Segunda configuração: imagens após o realce High-Boost com kernel 3x3.

5.2 Aplicação de métricas

Realizando o mesmo código aplicado à primeira configuração para gerar os resultados das métricas selecionadas, porém para a segunda configuração.

Imagem	Etapas	PSNR (db)	SSIM
1	Com Ruído	20.03	0.0983
2	Com Ruído	20.05	0.1155
3	Com Ruído	20.00	0.0908
4	Com Ruído	20.68	0.1996
1	Filtrada (Suavização)	35.99	0.8733
2	Filtrada (Suavização)	34.05	0.8467
3	Filtrada (Suavização)	36.08	0.8724
4	Filtrada (Suavização)	29.55	0.7960
1	Correção gamma (limitado)	26.32	0.8604
2	Correção gamma (limitado)	17.24	0.7766
3	Correção gamma (limitado)	21.72	0.8442
4	Correção gamma (limitado)	15.82	0.7174
1	Final (Highboost kernel 3x3 v2)	26.41	0.7868
2	Final (Highboost kernel 3x3 v2)	17.32	0.6998
3	Final (Highboost kernel 3x3 v2)	21.83	0.7626
4	Final (Highboost kernel 3x3 v2)	15.87	0.6395

Tabela 2 — Métricas aplicadas à segunda configuração.

6. Códigos importantes da implementação

6.1 Convolução Genérica

Função base utilizada por todas as etapas de filtragem espacial (suavização e aguçamento), com preenchimento de borda por reflexão:

```
def conv2d(img, kernel):
    kh, kw = kernel.shape
    pad_h, pad_w = kh // 2, kw // 2
    img_padded = np.pad(img.astype(np.float64),
                        ((pad_h, pad_h), (pad_w, pad_w)), mode='reflect')
    out = np.zeros_like(img, dtype=np.float64)
    for i in range(img.shape[0]):
        for j in range(img.shape[1]):
            out[i, j] = np.sum(img_padded[i:i+kh, j:j+kw] * kernel)
    return out
```

6.2 Kernel de Suavização (Filtro de Média)

```
def mean_kernel(size=3):
    return np.ones((size, size)) / (size * size)
```

6.3 Correção Gama e Cálculo Automático do Parâmetro

```
def gamma_correction(img, gamma=0.5, c=1.0):
    img_norm = img.astype(np.float64) / 255.0
    img_gamma = c * (img_norm ** gamma)
    return np.clip(img_gamma * 255, 0, 255).astype(np.uint8)

def auto_gamma(img, target_mean=0.5):
    mean_norm = np.mean(img) / 255.0
    if mean_norm <= 0:
        return 1.0
    gamma = np.log(target_mean) / np.log(mean_norm)
    return gamma

def auto_gamma_limitado(img, target_mean=0.5, gamma_min=0.5, gamma_max=2.0):
    mean_norm = np.mean(img) / 255.0
    if mean_norm <= 0:
        return 1.0
    gamma = np.log(target_mean) / np.log(mean_norm)
    return np.clip(gamma, gamma_min, gamma_max)
```

6.4 Aguçamento — Unsharp Masking / High-Boost Filtering

```
def unsharp_highboost(img, kernel_blur, k=1.0):
    blurred = np.clip(conv2d(img, kernel_blur), 0, 255).astype(np.uint8)
    mask = img.astype(np.float64) - blurred.astype(np.float64)
    sharpened = img.astype(np.float64) + k * mask
    return np.clip(sharpened, 0, 255).astype(np.uint8)
```

6.5 Métricas de Qualidade — MSE e PSNR

```
def mse(imageA, imageB):
    err = np.sum((imageA.astype("float") - imageB.astype("float")) ** 2)
    err /= float(imageA.shape[0] * imageA.shape[1])
    return err

def psnr(imageA, imageB):
    m = mse(imageA, imageB)
    if m == 0:
        return 100
    max_pixel = 255.0
    return 20 * np.log10(max_pixel / np.sqrt(m))

# SSIM utilizado via skimage.metrics.structural_similarity,
# por não se tratar de operação pontual/filtragem espacial.
```

7. Resultados obtidos

7.1 Parâmetros adotados

Parâmetros	Valor
Variância	0,01
Kernel	7x7
Alvo do gama	0,5
Limites gama	[0,5; 2,0]
Kernel do High-Boost	3x3
k	1
Métricas	PSNR / SSIM

Tabela 3 — Parâmetros adotados no código.

7.2 Estudo do kernel de suavização

Imagem	Kernel	PSNR (db)	SSIM
1	Suavização 3x3	29.45	0.5186
2	Suavização 3x3	29.27	0.5354
3	Suavização 3x3	29.39	0.4996
4	Suavização 3x3	28.37	0.6147
1	Suavização 5x5	33.59	0.7690

2	Suavização 5x5	32.71	0.7609
3	Suavização 5x5	33.56	0.7592
4	Suavização 5x5	29.71	0.7618
1	Suavização 7x7	35.99	0.8733
2	Suavização 7x7	34.05	0.8467
3	Suavização 7x7	36.08	0.8724
4	Suavização 7x7	29.55	0.7960
1	Suavização 9x9	37.47	0.9154
2	Suavização 9x9	34.47	0.8755
3	Suavização 9x9	37.75	0.9197
4	Suavização 9x9	29.03	0.7937
1	Suavização 11x11	38.36	0.9337
2	Suavização 11x11	34.49	0.8843
3	Suavização 11x11	38.89	0.9409
4	Suavização 11x11	28.45	0.7821

Tabela 4 — Valores das métricas para diferentes Kernels de suavização.

7.3 Estudo do kernel interno do High-Boost

Imagem	Kernel	PSNR (db)	SSIM
1	Highboost kernel 3x3	26.41	0.7868
2	Highboost kernel 3x3	17.32	0.6998
3	Highboost kernel 3x3	21.83	0.7626
4	Highboost kernel 3x3	10.09	0.4879
1	Highboost kernel 5x5	26.27	0.7491
2	Highboost kernel 5x5	17.29	0.6624
3	Highboost kernel 5x5	21.78	0.7215
4	Highboost kernel 5x5	10.08	0.4500

1	Highboost kernel 7x7	26.15	0.7241
2	Highboost kernel 7x7	17.27	0.6386
3	Highboost kernel 7x7	21.73	0.6941
4	Highboost kernel 7x7	10.06	0.4280

Tabela 5 — Valores das métricas para diferentes Kernels internos do High-Boost.

7.4 Comparação das configurações

	PSNR (db)	SSIM	PSNR (db)	SSIM
Imagem / Etapa	Config 1		Config 2	
1	26.41	0.7868	26.41	0.7868
2	17.32	0.6998	17.32	0.6998
3	21.83	0.7626	21.83	0.7626
4	10.09	0.4879	15.87	0.6395

Tabela 6 — Comparação dos valores das métricas da imagem final, nas duas configurações após a aplicação do High-Boost.

7.5 Investigação da Imagem 2

Imagem	Desvio-padrão global	Média da imagem	Média da borda (10px)	Diferença (borda-média)
1	34.32	139.26	158.12	18.86
2	37.11	164.23	104.24	-59.98
3	18.77	147.84	145.48	-2.36
4	28.02	210.92	191.17	-19.75

Tabela 7 — Análise da diferença de intensidade entre as bordas e a imagem.

8. Análise e discussão sobre os resultados finais

8.1 Etapa de ruído

Com a variabilidade escolhida 0,01, o PSNR inicial ficou entre 20.00 e 20.68 dB nas quatro imagens, o que são valores próximos ao limiar considerado bom (20 dB) indicado

no material da disciplina, porém o SSI ficou muito baixo (0,09 a 0,20). Essa discrepância é esperada: o PSNR mede apenas o erro médio de intensidade por pixel, enquanto o SSIM é sensível à estrutura local; o ruído gaussiano aditivo, embora produza um erro médio moderado, destrói a correlação estrutural local de forma muito mais severa, o que explica a queda desproporcional do SSIM em relação ao PSNR nesta etapa.

8.2 Etapa de suavização e trade-off do tamanho do kernel

A suavização recuperou fortemente ambas as métricas em todos os tamanhos de kernel testados (Tabela 1). Entretanto, o comportamento não foi uniforme entre as quatro imagens: enquanto as Imagens 1 e 3 continuaram melhorando até 11×11 , a Imagem 4 atingiu seu pico de PSNR em 5×5 (29.71 dB) e de SSIM em 7×7 (0.7960), caindo a partir daí. Esse comportamento é consistente com o fato de a Imagem 4 apresentar, desde a etapa de ruído, o melhor PSNR das quatro (ou seja, menos ruído residual a remover); ao continuar aumentando o kernel, a suavização passa a remover estrutura real da lesão, não apenas ruído. Esse resultado ilustra diretamente um dos desafios apontados no enunciado do trabalho: uma técnica que apresenta bom resultado em uma imagem pode não ser a mais adequada para outra, exigindo análise individualizada. O kernel 7×7 foi adotado como ponto de equilíbrio — o maior tamanho em que todas as quatro imagens ainda se beneficiam da suavização.

8.3 Diagnóstico de assimetria e a comparação entre configurações

A visualização dos histogramas, na Figura 5, nos permite observar nas quatro imagens, que os histogramas são fortemente assimétricos, o que justifica o porquê de não usar alargamento de contraste linear. Isso também reforça que a escolha da correção gamma não foi arbitrária, mas derivada de um critério de diagnóstico aplicado antes da escolha da técnica, e não depois de observar qual delas produzia o melhor resultado numérico.

A comparação entre a Configuração 1 (gama sem limite) e a Configuração 2 (gama limitado a $[0.5, 2.0]$) evidenciou um problema específico: como a fórmula do gama automático busca levar a média de qualquer imagem para o mesmo alvo fixo (0.5), imagens naturalmente mais claras (caso da Imagem 4) recebem uma correção desproporcionalmente mais agressiva (gama calculado em 3.43) do que imagens já próximas do alvo. Isso fez a Imagem 4 cair de PSNR 29.55 dB (etapa filtrada) para 10.07 dB após o gama sem limite — uma queda muito maior que a das demais imagens (Tabela 1). Ao limitar o gama ao intervalo $[0.5, 2.0]$, apenas a Imagem 4 foi afetada (as demais já estavam dentro do intervalo), e seu resultado final subiu de PSNR 10.09/SSIM 0.4879 para PSNR 15.87/SSIM 0.6395 (Tabela 2) — uma correção cirúrgica que resolveu o caso problemático sem alterar o comportamento das demais imagens, exatamente a comparação de configurações solicitada no enunciado do trabalho.

8.4 Etapa de aguçamento e escolha do kernel interno

A comparação de kernels internos do Unsharp Masking/High-Boost (Tabela 5) mostrou queda monotônica de PSNR e SSIM conforme o kernel de borrimento interno aumentava, de forma consistente nas quatro imagens — o oposto do comportamento observado no kernel de suavização principal. Essa diferença tem explicação técnica: no High-Boost, o kernel de borrimento interno define o que é tratado como "detalhe" a ser realçado ($\text{mask} = \text{imagem} - \text{borrada}$); um kernel maior incorpora informação de frequência mais baixa nessa máscara, tornando o realce menos cirúrgico e mais distante da imagem original. O kernel 3×3 foi adotado por produzir o realce mais contido e mais fiel, coerente com o papel dessa etapa — realçar detalhe fino, não redistribuir contraste global.

8.5 Comparação do pipeline completo

Consolidando as escolhas (suavização 7×7 , gama limitado, aguçamento com kernel interno 3×3), o resultado final da Configuração 2 superou na imagem 4. Onde o PSNR subiu de 10,09 dB para 15,87 dB e o SSIM subiu de 0,4879 para 0,6395, o que demonstra que o ajuste teve impacto no resultado final.

8.6 Dificuldades com a imagem 2

Mesmo após as correções aplicadas, a Imagem 2 permanece com o pior desempenho relativo na etapa final (PSNR 17.32 dB, SSIM 0.7008 — Tabela 2). A investigação da Tabela 7 ajuda a explicar o motivo: o desvio-padrão global da Imagem 2 (37.1) é, na verdade, o maior entre as quatro, o que descarta a hipótese inicial de que a lesão seria simplesmente "pouco visível" ou de baixo contraste. Em contrapartida, a diferença entre a média da faixa de borda (10 px) e a média geral da imagem é de aproximadamente -60 níveis de cinza — uma discrepância muito maior que a observada em qualquer uma das outras três imagens (que variam entre -19.7 e +18.8). Esse resultado é consistente com a presença de uma vinheta ou moldura escura nos cantos da captura, comum em imagens de dermatoscópio. Essa diferença de intensidade entre a borda e a imagem (i) distorce a média utilizado no cálculo do gama automático, mesmo com limite aplicado; e (ii) cria uma transição artificial de intensidade entre a borda escura e a pele.

8.7 Conclusão da análise

O pipeline final recomendado por este trabalho é: conversão para escala de cinza ponderada -> suavização com kernel de média 7×7 -> correção gama automática limitada ao intervalo $[0.5, 2.0]$ -> aguçamento por Unsharp Masking/High-Boost com kernel interno 3×3 e $k = 1.0$. Essa configuração (Configuração 2) demonstrou, com base em PSNR e SSIM, ser igual ou superior à Configuração 1 nas quatro imagens testadas, sem introduzir nenhuma regressão. As limitações identificadas no trabalho, foram a ausência de um

kernel de suavização adaptado por imagem, estes problemas que não invalidam a conclusão de que o pipeline atinge o objetivo proposto: reduzir ruído e realçar estruturas relevantes da lesão sem introduzir distorções que comprometam sua interpretação.

9. Considerações finais

Este trabalho demonstrou, por meio de investigação sistemática (e não apenas aplicação direta de filtros), que a escolha de técnicas e parâmetros de processamento de imagens deve ser fundamentada em diagnóstico prévio das características de cada imagem — como a assimetria do histograma, para a operação pontual, e a análise de sensibilidade por imagem, para os tamanhos de kernel de suavização e aguçamento — em vez de escolhas arbitrárias validadas apenas a posteriori pelo resultado numérico. O código completo, o notebook executável e as imagens utilizadas estão disponíveis no [repositório Github](#).